


# BACHELOR THESIS

JAN LAMMEL



Untersuchung des Multicut Problems bei Verwendung einer Variation of  
Information Loss Funktion

September 2015

Jan Lammel: *Bachelor Thesis*, Untersuchung des Multicut Problems bei Verwendung einer Variation of Information Loss Funktion, © September 2015

## ABSTRACT

---

Short summary of the contents in English...a great guide by Kent Beck how to write good abstracts can be found here:

<https://plg.uwaterloo.ca/~migod/research/beck00PSLA.html>

## ZUSAMMENFASSUNG

---

Kurze Zusammenfassung des Inhaltes in deutscher Sprache...



# INHALTSVERZEICHNIS

---

1	EINLEITUNG	1
2	THEORETISCHE GRUNDLAGEN	3
2.1	Graphen Theorie	3
2.2	Feature Space	3
2.3	Das Multicut Problem	3
2.4	Loss Funktionen	4
2.4.1	Partition Hamming	4
2.4.2	Variation of Information	4
2.5	Structured Learning	4
2.5.1	Subgradient Descent	5
2.5.2	Stochastic Gradient	5
3	EXPERIMENTELLES SETUP	7
3.1	Trainings- und Testdaten	7
3.2	Feature Space	7
I	APPENDIX	9
A	APPENDIX TEST	11
	LITERATURVERZEICHNIS	13



## EINLEITUNG

---

Das weite Forschungsfeld der Bildsegmentierung handelt von der Problemstellung, Bilder automatisiert in einzelne semantisch sinnvolle Segmente zu unterteilen. Anwendungsgebiete finden sich unter anderem in der Objekterkennung, Biologie, Medizin und allgemein Bildanalyse-Methoden, wobei die Segmentierung als Vorstufe zur weiteren Bearbeitung dient.

(Hier Bild einfügen: Bild ohne Segmentierung -> Bild mit gewünschter Segmentierung)

Dieser Prozess soll Lern-basiert sein, d.h. es werden dem Algorithmus Trainingsdaten mit Beispielbildern inklusive Soll-Segmentierung (Ground Truth) übergeben. Anhand dieser werden Parameter optimiert um möglichst allgemeingültig, den Trainingsdaten ähnliche Bilder ebenso in einzelne Segmente gliedern zu können.

In dieser Arbeit wird nun eine neue Methode zur Quantifizierung der Qualität einer Segmentierung vorgestellt und mit einer bestehenden verglichen. Da der Lern-Algorithmus auf diesem Kriterium aufbaut, ist dies elementar für die Güte der resultierenden Segmentierung.





## 2.1 GRAPHEN THEORIE

Die Grundlage aller weiteren Betrachtungen ist ein Region Adjacency Graph (RAG). Um diesen zu erstellen, wird das Bild zunächst mithilfe des SLIC-Algorithmus (Zitat!) in Superpixel unterteilt, dessen Ränder möglichst an den Objektkonturen verlaufen. Das Ergebnis hiervon ist in (Abb verlinken) abgebildet.

Der Region Adjacency Graph  $G$  baut sich aus Nodes  $V$  und Edges  $E$  auf. In unserem Fall entsprechen die Nodes den Superpixeln. Die Edges bestehen nur zwischen denjenigen Nodes, bei denen die zugehörigen Superpixel direkt angrenzen und somit eine gemeinsame Kante besitzen.

(hier SLIC-partition Bild und RAG-Bild einfügen)

Bei der letztlichen Segmentierung geht es darum, ein konsistentes Labeling der Superpixel zu erreichen. Dies wird über die Aktivität der Edges erreicht, welche an- oder ausgeschaltet sein können. Für die Aktivität einer Edge  $y$  gilt somit:  $y \in \{0, 1\}$

Konsistent ist eine Segmentierung genau dann, wenn bei aktiven Edges die zugehörigen Superpixel verschiedene Labels haben und analog bei inaktiven Edges die Superpixel die gleichen Labels. Anschaulich gesehen ist dies der Fall, wenn alle aktiven Edges geschlossene Linien bilden.

## 2.2 FEATURE SPACE

Der Feature Space  $X \in \mathbb{R}^{|E| \times D}$  ordnet jeder Edge  $D$  Features zu, die möglichst in Korrelation zur Frage stehen, ob die betrachtete Edge nun aktiv oder inaktiv sein soll.

## 2.3 DAS MULTICUT PROBLEM

Anhand dieser gewichteten Edges eine konsistente Segmentierung zu erhalten wird als Multicut Problem (MP) bezeichnet. Es wird durch folgendes Minimierungsproblem beschrieben:

$$\begin{aligned} \arg \min_{y_e} \quad & \sum_{y \in E} w \beta_e \cdot y \\ \text{s.t.} \quad & y - \sum_{y_i \in P(y)} y_i \leq 0 \quad \forall y \in E \end{aligned} \quad (1)$$

Hierbei entspricht  $w \in \mathbb{R}^D$  den Weights und  $\beta_e \in \mathbb{R}^D$  den Funktionswerten der  $D$  extrahierten Informationen des Feature Spaces. Die Nebenbedingungen erzwingen die Konsistenz der Segmentierung.  $P(y)$  ist hierbei der kürzeste Pfad über inaktive Edges der beiden Superpixel, die benachbart zu  $y$  sind. In der Praxis wird das Minimierungsproblem zunächst ohne Constraints gelöst und anschließend solange für Edges hinzugefügt, die die Konsistenzbedingung verletzen, bis Konsistenz erreicht ist.

## 2.4 LOSS FUNKTIONEN

Mithilfe einer Loss Funktion  $\mathcal{L}(y, y^*)$  wird quantifiziert, wie gut eine Segmentierung  $y$  mit derjenigen der Ground Truth  $y^*$  übereinstimmt. In dieser Arbeit wird die neue Methode "Variation of Information" vorgestellt und mit der bestehenden "Partition Hamming" verglichen.

### 2.4.1 Partition Hamming

$$\mathcal{L}(y_i, y_i^*) = \begin{cases} \mathbb{I}[y_i \neq y_i^*] \cdot \alpha_{\text{over}} & \text{if } y_i^* = 0 \\ \mathbb{I}[y_i \neq y_i^*] \cdot \alpha_{\text{under}} & \text{if } y_i^* = 1 \end{cases} \quad \forall y_i \in E \quad (2)$$

$$\mathcal{L}(y, y^*) = \sum_{y_i \in E} \mathcal{L}(y_i, y_i^*) \quad (3)$$

Es werden direkt die Edges der Segmentierung  $y$  und der Ground Truth  $y^*$  verglichen und bei fehlender Übereinstimmung erhöht sich der Loss. Meist ist  $\alpha_{\text{under}} > \alpha_{\text{over}}$  um Übersegmentierung zu bevorzugen, da es tragischer ist Objekte nicht zu erfassen.

### 2.4.2 Variation of Information

$$\mathcal{L}(y, y^*) = H_y + H_{y^*} - 2 \cdot I(y, y^*) \quad (4)$$

$H_x$  ist hierbei die Entropie der Segmentierung  $x$ . Jede Segmentierung besitzt eine individuelle Entropie.

$I(x, x^*)$  bezeichnet die Transinformation, anschaulich gesehen entspricht diese der Schnittmenge der Ist- und Soll-Segmentierung. Es werden also die Labels der Superpixel untersucht und bei fehlender Übereinstimmung beim Vergleich mit der Ground Truth erhöht sich der Loss.

## 2.5 STRUCTURED LEARNING

Um später mithilfe des Multicut Algorithmus Bilder möglichst gut segmentieren zu können, muss der Parameter  $w$  bestimmt werden. "Möglichst gut" bedeutet hier in Bezug auf eine Loss Funktion, die als

Qualitätskriterium dient. Da ein niedriger Loss für eine gute Segmentierung steht ist also das folgende Minimierungsproblem zu lösen:

$$\hat{w} = \arg \min_w \mathcal{L}(y, y^*) \quad (5)$$

### 2.5.1 Subgradient Descent

Der Subgradient Descent Algorithmus basiert auf der Berechnung der Differenz der akkumulierten Feature der Segmentierung  $y$  und der Ground Truth  $y^*$ , welche gewichtet dem weight Vector  $w$  hinzuaddiert werden. Für nähere Details siehe [1].

Die Minimierung des Partition Hamming Losses in dieser Arbeit wird hiermit realisiert.

### 2.5.2 Stochastic Gradient

Der hier verwendete Stochastic Gradient ist eine Variante des in [1] näher erläuterten Algorithmus. Nachdem wie gewöhnlich bei Stochastic Gradient ein zufälliges Training Sample gewählt wurde, wird folgendermaßen die Gradientenrichtung bestimmt: Es wird zum momentanen Weight Vector  $n$  mal ein normalverteilter Noise hinzuaddiert. Für jeden dieser verrauschten Weights wird der Loss bezüglich des momentan betrachteten Bildes berechnet. Es wird nun, gewichtet nach der Veränderung im Loss, aus dem Noise die Gradientenrichtung berechnet. Je stärker der Loss gestiegen ist, desto größer ist sein Einfluss auf die neue Richtung. Analog mit gesunkenem Loss. Die beste Schrittweite wird nun ermittelt, indem der durchschnittliche Loss über das gesamte Trainingsset für verschiedene äquidistante Schrittweiten berechnet wird. Es wird diejenige Schrittweite mit dem niedrigsten Loss gewählt und falls ein neues globales Minimum gefunden wurde, der weight Vector gespeichert.

vllt später mal so... :

---

#### Algorithm 1 Stochastic Gradient Descent

---

1: **procedure** STOCHASTICGRADIENTDESCENT( $T, \eta$ )

---



## EXPERIMENTELLES SETUP

---

### 3.1 TRAININGS- UND TESTDATEN

Zum einen wurden Experimente an kleinen synthetisch erzeugten Bildern durchgeführt um die prinzipiellen Vorteile von Variation of Information zu demonstrieren.

Zum Anderen diente für die umfassenderen Experimente zur praktischen Anwendung das Berkeley Segmentation Dataset (BSD500) [2], welches aus natürlichen Bildern besteht. Es wurden hiervon die Test-Bilder genommen, da hierfür State of the Art Kantendetektoren als Feature zur Verfügung standen.

### 3.2 FEATURE SPACE

Für die synthetischen Daten wurden folgende Feature gewählt:

- Gaussian Gradient Magnitude mit  $\sigma = 1$
- Hessian of Gaussian Eigenvalues mit  $\sigma = 1$
- Structure Tensor Eigenvalues

Beim BSD hat sich der Feature Space folgendermaßen zusammengesetzt:

- Gaussian Gradient Magnitude mit  $\sigma = \{1, 2, 5\}$
- Hessian of Gaussian Eigenvalues mit  $\sigma = 2$
- Laplacian of Gaussian
- Structure Tensor Eigenvalues
- Canny Filter
- Statistische Kenndaten in variablen Bereichen  $\bar{u}$  und  $\bar{v}$  um eine Edge an Superpixeln  $u$  und  $v$ 
  - $\text{Mean}(\bar{u} + \bar{v})$
  - $\text{Variance}(\bar{u} + \bar{v})$
  - $\frac{\max\{\text{Mean}(\bar{u}), \text{Mean}(\bar{v})\}}{\min\{\text{Mean}(\bar{u}), \text{Mean}(\bar{v})\}}$
  - $\frac{\max\{\text{Median}(\bar{u}), \text{Median}(\bar{v})\}}{\min\{\text{Median}(\bar{u}), \text{Median}(\bar{v})\}}$
  - $\text{Skewness}(\bar{u} + \bar{v})$
  - $\text{Kurtosis}(\bar{u} + \bar{v})$
-



Teil I

APPENDIX









[?]



## LITERATURVERZEICHNIS

---

- [1] Sebastian Nowozin, Christoph H. Lampert, *Structured Learning and Prediction in Computer Vision*, 2011.
- [2] D. Martin, C. Fowlkes, D. Tal and J. Malik, *A Database of Human Segmented Natural Images and its Application to Evaluating Segmentation Algorithms and Measuring Ecological Statistics*, Proc. 8th Int'l Conf. Computer Vision, July 2001



## DECLARATION

---

Put your declaration here.

*Saarbrücken, September 2015*

---

Jan Lammel