


# BACHELOR THESIS

JAN LAMMEL



Untersuchung des Multicut Problems bei Verwendung einer Variation of  
Information Loss Funktion

September 2015

Jan Lammel: *Bachelor Thesis*, Untersuchung des Multicut Problems bei Verwendung einer Variation of Information Loss Funktion, © September 2015

## ABSTRACT

---

Short summary of the contents in English...a great guide by Kent Beck how to write good abstracts can be found here:

<https://plg.uwaterloo.ca/~migod/research/beck00PSLA.html>

## ZUSAMMENFASSUNG

---

Kurze Zusammenfassung des Inhaltes in deutscher Sprache...



# INHALTSVERZEICHNIS

---

<b>I</b>	<b>SOME KIND OF MANUAL</b>	<b>1</b>
1	EINLEITUNG	3
<b>II</b>	<b>THE SHOWCASE</b>	<b>5</b>
2	THEORETISCHE GRUNDLAGEN	7
2.1	Graphen Theorie	7
2.2	Feature Space	7
2.3	Das Multicut Problem	7
2.4	Loss Funktionen	8
2.4.1	Partition Hamming	8
2.4.2	Variation of Information	8
2.5	Structured Learning	8
2.5.1	Subgradient Descent	9
2.5.2	Stochastic Gradient	9
3	EXPERIMENTELLER AUFBAU	11
3.1	Feature Space	11
<b>III</b>	<b>APPENDIX</b>	<b>13</b>
A	APPENDIX TEST	15
	LITERATURVERZEICHNIS	17

## ABBILDUNGSVERZEICHNIS

---

## TABELLENVERZEICHNIS

---

## LISTINGS

---

## ACRONYMS

---

Teil I

SOME KIND OF MANUAL





## EINLEITUNG

---

Das weite Forschungsfeld der Bildsegmentierung handelt von der Problemstellung, Bilder automatisiert in einzelne semantisch sinnvolle Segmente zu unterteilen. Anwendungsgebiete finden sich unter anderem in der Objekterkennung, Biologie, Medizin und allgemein Bildanalyse-Methoden, wobei die Segmentierung als Vorstufe zur weiteren Bearbeitung dient.

(Hier Bild einfügen: Bild ohne Segmentierung -> Bild mit gewünschter Segmentierung)

Dieser Prozess soll Lern-basiert sein, d.h. es werden dem Algorithmus Trainingsdaten mit Beispielbildern inklusive Soll-Segmentierung (Ground Truth) übergeben. Anhand dieser werden Parameter optimiert um möglichst allgemeingültig, den Trainingsdaten ähnliche Bilder ebenso in einzelne Segmente gliedern zu können.

In dieser Arbeit wird nun eine neue Methode zur Quantifizierung der Qualität einer Segmentierung vorgestellt und mit einer bestehenden verglichen. Da der Lern-Algorithmus auf diesem Kriterium aufbaut, ist dies elementar für die Güte der resultierenden Segmentierung.



## Teil II

### THE SHOWCASE

You can put some informational part preamble text here.  
Illo principalmente su nos. Non message *occidental* anglo-romanian da. Debitas effortio simplicate sia se, auxiliar summarios da que, se avantiate publicationes via. Pan in terra summarios, capital interlingua se que. Al via multo esser specimen, campo responder que da. Le usate medical addresses pro, europa origine sanctificate nos se.



## 2.1 GRAPHEN THEORIE

Die Grundlage aller weiteren Betrachtungen ist ein Region Adjacency Graph (RAG). Um diesen zu erstellen, wird das Bild zunächst mithilfe des SLIC-Algorithmus (Zitat!) in Superpixel unterteilt, dessen Ränder möglichst an den Objektkonturen verlaufen. Das Ergebnis hiervon ist in (Abb verlinken) abgebildet.

Der Region Adjacency Graph  $G$  baut sich aus Nodes  $V$  und Edges  $E$  auf. In unserem Fall entsprechen die Nodes den Superpixeln. Die Edges bestehen nur zwischen denjenigen Nodes, bei denen die zugehörigen Superpixel direkt angrenzen und somit eine gemeinsame Kante besitzen.

(hier SLIC-partition Bild und RAG-Bild einfügen)

Bei der letztlichen Segmentierung geht es darum, ein konsistentes Labeling der Superpixel zu erreichen. Dies wird über die Aktivität der Edges erreicht, welche an- oder ausgeschaltet sein können. Für die Aktivität einer Edge  $y$  gilt somit:  $y \in \{0, 1\}$

Konsistent ist eine Segmentierung genau dann, wenn bei aktiven Edges die zugehörigen Superpixel verschiedene Labels haben und analog bei inaktiven Edges die Superpixel die gleichen Labels. Anschaulich gesehen ist dies der Fall, wenn alle aktiven Edges geschlossene Linien bilden.

## 2.2 FEATURE SPACE

Der Feature Space  $F \in \mathbb{R}^{|E| \times D}$  ordnet jeder Edge  $D$  Features zu, die möglichst in Korrelation zur Frage stehen, ob die betrachtete Edge nun aktiv oder inaktiv sein soll.

## 2.3 DAS MULTICUT PROBLEM

Anhand dieser gewichteten Edges eine konsistente Segmentierung zu erhalten wird als Multicut Problem (MP) bezeichnet. Es wird durch folgendes Minimierungsproblem beschrieben:

$$\begin{aligned} \arg \min_{y_e} \quad & \sum_{y \in E} w \beta_e \cdot y \\ \text{s.t.} \quad & y - \sum_{y_i \in P(y)} y_i \leq 0 \quad \forall y \in E \end{aligned} \quad (1)$$

Hierbei entspricht  $w \in \mathbb{R}^D$  den Weights und  $\beta_e \in \mathbb{R}^D$  den Funktionswerten der  $D$  extrahierten Informationen des Feature Spaces. Die Nebenbedingungen erzwingen die Konsistenz der Segmentierung.  $P(y)$  ist hierbei der kürzeste Pfad über inaktive Edges der beiden Superpixel, die benachbart zu  $y$  sind. In der Praxis wird das Minimierungsproblem zunächst ohne Constraints gelöst und anschließend solange für Edges hinzugefügt, die die Konsistenzbedingung verletzen, bis Konsistenz erreicht ist.

## 2.4 LOSS FUNKTIONEN

Mithilfe einer Loss Funktion  $\mathcal{L}(y, y^*)$  wird quantifiziert, wie gut eine Segmentierung  $y$  mit derjenigen der Ground Truth  $y^*$  übereinstimmt. In dieser Arbeit wird die neue Methode "Variation of Information" vorgestellt und mit der bestehenden "Partition Hamming" verglichen.

### 2.4.1 Partition Hamming

$$\mathcal{L}(y_i, y_i^*) = \begin{cases} \mathbb{I}[y_i \neq y_i^*] \cdot \alpha_{\text{over}} & \text{if } y_i^* = 0 \\ \mathbb{I}[y_i \neq y_i^*] \cdot \alpha_{\text{under}} & \text{if } y_i^* = 1 \end{cases} \quad \forall y_i \in E \quad (2)$$

$$\mathcal{L}(y, y^*) = \sum_{y_i \in E} \mathcal{L}(y_i, y_i^*) \quad (3)$$

Es werden direkt die Edges der Segmentierung  $y$  und der Ground Truth  $y^*$  verglichen und bei fehlender Übereinstimmung erhöht sich der Loss. Meist ist  $\alpha_{\text{under}} > \alpha_{\text{over}}$  um Übersegmentierung zu bevorzugen, da es tragischer ist Objekte nicht zu erfassen.

### 2.4.2 Variation of Information

$$\mathcal{L}(y, y^*) = H_y + H_{y^*} - 2 \cdot I(y, y^*) \quad (4)$$

$H_x$  ist hierbei die Entropie der Segmentierung  $x$ . Jede Segmentierung besitzt eine individuelle Entropie.

$I(x, x^*)$  bezeichnet die Transinformation, anschaulich gesehen entspricht diese der Schnittmenge der Ist- und Soll-Segmentierung. Es werden also die Labels der Superpixel untersucht und bei fehlender Übereinstimmung beim Vergleich mit der Ground Truth erhöht sich der Loss.

## 2.5 STRUCTURED LEARNING

Um später mithilfe des Multicut Algorithmus Bilder möglichst gut segmentieren zu können, muss der Parameter  $w$  bestimmt werden. "Möglichst gut" bedeutet hier in Bezug auf eine Loss Funktion, die als

Qualitätskriterium dient. Da ein niedriger Loss für eine gute Segmentierung steht ist also das folgende Minimierungsproblem zu lösen:

$$\hat{w} = \arg \min_w \mathcal{L}(y, y^*) \quad (5)$$

### 2.5.1 *Subgradient Descent*

Der Subgradient Descent Algorithmus basiert auf der Berechnung der Differenz der akkumulierten Feature der Segmentierung  $y$  und der Ground Truth  $y^*$ , welche gewichtet dem weight Vector  $w$  hinzugeaddiert werden. Für nähere Details siehe [?]

### 2.5.2 *Stochastic Gradient*





## EXPERIMENTELLER AUFBAU

---

bli bla blubb

### 3.1 FEATURE SPACE



Teil III

APPENDIX







[?]





## LITERATURVERZEICHNIS

---

- [1] Sebastian Nowozin, Christoph H. Lampert, *Structured Learning and Prediction in Computer Vision*, 2011.



## DECLARATION

---

Put your declaration here.

*Saarbrücken, September 2015*

---

Jan Lammel