

Bachelor Thesis

Vergleich von Hamming- und Variation of Information-Loss
basiertem strukturiertem Parameterlernen beim Multicut
Problem

Jan Lammel

12. Februar 2016

Inhaltsverzeichnis

1 Einleitung

2 Theoretische Grundlagen

3 Experimentelles Setup

4 Experimente und Resultate

5 Fazit

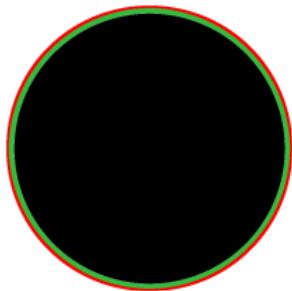
Segmentierung



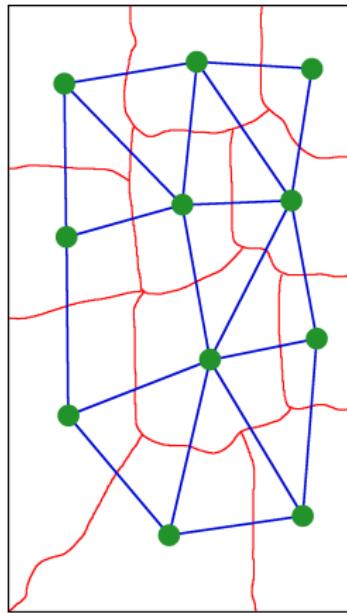
Motivation Variation of Information



- Hamming Loss stark abhaengig vom genauen Verlauf der Segmentierung
- Aber: Verlauf der Segmentierung oft nicht eindeutig
- Idee VOI: Betrachte Label der Segmentierung und bestrafen flaechenabhaengig



Region Adjacency Graph (RAG)



- Bild mittels SLIC in **Superpixel** (SP) unterteilt
- Jeder Superpixel $\hat{=}$ **Knoten** im RAG
- Direkt benachbarte SP erzeugen **Kanten** zwischen entsprechenden Knoten

Multicut Problem (MP)

$$\begin{aligned} \min_y \quad & \sum_{y_i \in E} \langle w, \beta_e \rangle \cdot y_i \\ \text{s.t.} \quad & y - \sum_{y_i \in P(y)} y_i \leq 0 \quad \forall y \in E \end{aligned}$$

to-do

to-do

Trainings- und Testdaten

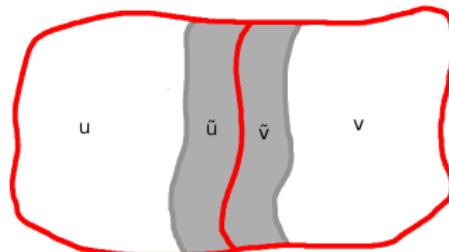
- Natuerliche Bilder vom Berkeley Segmentation Dataset (BSD-500)
- Davon die 200 Bilder des Testsets verwendet da hierfuer state-of-the-art Kantendetektoren zur Verfuegung standen
→ je 100 Trainings- und Testbilder
- Ground Truth ebenso aus BSD-500 Datensatz (mittels Majority Vote Label der SP bestimmt)

Feature Space

- Gaussian Gradient Magnitude
- Hessian of Gaussian Eigenwerte
- Laplacian of Gaussian
- Structure Tensor Eigenwerte
- Canny Filter
- N^4 -Fields [?] mit und ohne Gewichtung der Kantenlaenge
- Dollár et. al [?] Kantendetektor mit und ohne Gewichtung der Kantenlaenge

Feature Space

- Statistische Kenndaten in variablen Bereichen \tilde{u} und \tilde{v} um Kante der SP u und v:
 - Mean($\tilde{u} + \tilde{v}$)
 - Variance($\tilde{u} + \tilde{v}$)
 - $\max \{\text{Mean}(\tilde{u}), \text{Mean}(\tilde{v})\}$
 - $\min \{\text{Mean}(\tilde{u}), \text{Mean}(\tilde{v})\}$
 - $\max \{\text{Median}(\tilde{u}), \text{Median}(\tilde{v})\}$
 - $\min \{\text{Median}(\tilde{u}), \text{Median}(\tilde{v})\}$
 - Skewness($\tilde{u} + \tilde{v}$)
 - Kurtosis($\tilde{u} + \tilde{v}$)
- Konstantes Feature zur Beseitigung des Bias der Decision Boundary
- Random Forest Feature aus den bisher genannten



Stochastic Gradient mit RF Feature

- Einstellungen variiert:
 - Definitionsbereich Feature Space
 - Constraint auf RF Feature
 - Subgradient Descent mit/ohne RF Feature
- Ergebnisse:
 - Verringerung des VOI Loss fuehrt auch auf Abfall des Hamming Loss im Trainingsset
 - Geschwindigkeit des Abfalls stark von Konfiguration abhangig ausserdem starke Schwankungen da stochastischer Prozess
 - Verringerung Loss auf Trainingsset \propto Erhoehung Loss auf Testset
⇒ Overfit der Trainingsdaten

Fazit